INSTITUTO DE EDUCACIÓN SUPERIOR TECNOLÓGICO PRIVADO CERTUS

“Año de la Recuperación y Consolidación de la Economía Peruana"”

UNIDAD DIDÁCTICA:

INTEGRANTES DEL GRUPO:

- ABIGAIL NICOL SULCA JAIMES
- AXEL BRYAN UKUNCHAM MOLINA
- JORDAN ANGEL HUERTAS NEGRON

CICLO: VI

SECCIÓN: 621M

TURNO: Mañana

DOCENTE: Alberto Edu Fernandez Bernedo

Introducción

En la actualidad, el correo electrónico se ha consolidado como una de las principales herramientas de comunicación en el ámbito personal, académico y empresarial. Sin embargo, el crecimiento exponencial del intercambio de mensajes ha traído consigo un incremento significativo de los correos no deseados o *spam*, los cuales representan una amenaza tanto para la productividad de los usuarios como para la seguridad de la información. Estos mensajes no solo generan pérdida de tiempo al tener que ser revisados y eliminados, sino que también pueden contener intentos de fraude, *phishing* o la propagación de software malicioso.

Ante esta problemática, la inteligencia artificial surge como una solución efectiva y escalable. En particular, las técnicas de aprendizaje automático (machine learning) permiten entrenar modelos capaces de identificar patrones en los correos electrónicos y clasificarlos automáticamente en dos categorías: mensajes legítimos (*no spam*) y mensajes no deseados (*spam*). Este enfoque no solo optimiza la gestión de la bandeja de entrada, sino que también refuerza la protección del usuario frente a ataques cibernéticos.

El presente informe desarrolla la primera parte de un proyecto académico orientado a la detección de spam en correos electrónicos mediante inteligencia artificial, abordando la descripción de los algoritmos aplicables, la formulación del problema como tarea de IA, la definición de la variable objetivo, la identificación de fuentes de datos y el diseño de un flujo de trabajo que permita implementar una solución práctica y eficiente.

Descripción de tipos de algoritmos de Machine Learning y usos

La detección de spam es un problema de clasificación supervisada, lo que significa que entrenamos un modelo con datos etiquetados (correos que ya se sabe si son spam o no). El objetivo es que el modelo aprenda a predecir la etiqueta de nuevos correos. Los algoritmos más comunes para esta tarea son:

- **Naive Bayes:** Este es un clasificador probabilístico basado en el teorema de Bayes. Es muy popular para la clasificación de texto porque es rápido, eficiente y funciona bien incluso con conjuntos de datos grandes. Su simplicidad radica en la suposición de que todas las palabras en un correo son independientes entre sí, lo cual, aunque no es totalmente cierto, da resultados sorprendentemente buenos en la práctica.
- **Support Vector Machines (SVM):** Este algoritmo busca el hiperplano óptimo (una línea en 2D, un plano en 3D, etc.) que mejor separe los datos en dos clases (spam y no spam). Es muy efectivo para problemas de clasificación en espacios de alta dimensión, como el que se crea al representar las palabras de un correo.
- **Bosques Aleatorios (Random Forest):** Es un método de aprendizaje conjunto que construye múltiples árboles de decisión y combina sus predicciones. Cada árbol se entrena con una submuestra aleatoria de los datos, lo que ayuda a reducir el sobreajuste y a mejorar la precisión general. Es un algoritmo robusto y versátil.

Identificación de situaciones problemáticas reales y factibilidad de mejora con IA

- Problema: El volumen masivo de correos electrónicos no deseados (spam) representa una molestia diaria que afecta la productividad y la seguridad de los usuarios. Estos correos no solo llenan la bandeja de entrada, dificultando la búsqueda de mensajes importantes, sino que también pueden contener malware, intentos de phishing o estafas, poniendo en riesgo la información personal y financiera.
- Factibilidad de mejora con IA: El problema es altamente factible de resolver con inteligencia artificial. La IA, específicamente el machine learning, puede aprender patrones complejos en el texto, los metadatos y la estructura de los correos que los humanos no podríamos procesar a esa escala. Un modelo de IA puede analizar miles de características (palabras clave, remitentes, enlaces sospechosos, hora de envío) en milisegundos para determinar la probabilidad de que un correo sea spam, proporcionando una solución automatizada, escalable y en tiempo real.

Formulación de la situación problemática como problema de IA

El problema de diferenciar correos importantes de correos no deseados (spam) se puede plantear como un problema de clasificación supervisada, que es un enfoque del aprendizaje automático en el cual un modelo se entrena a partir de datos previamente etiquetados.

En este caso, se cuenta con correos electrónicos que ya han sido clasificados como *spam* o *no spam* (también llamados “ham”). Estos ejemplos sirven como conjunto de entrenamiento para que el modelo de inteligencia artificial aprenda los patrones característicos que distinguen a cada clase.

- Entradas (features): El sistema analiza diferentes características de cada correo electrónico, tales como:
    - Contenido del mensaje (palabras clave, frecuencia de términos, uso de mayúsculas, símbolos o enlaces).
    - Información del remitente (dirección, dominio o reputación).

    - Estructura del correo (presencia de archivos adjuntos, enlaces sospechosos, asunto del mensaje).
    - Metadatos adicionales (hora de envío, encabezados técnicos).

- Salida (variable de decisión): El modelo devuelve una clasificación binaria:
    - 0 → No Spam (correo legítimo)
    - 1 → Spam (correo no deseado)

De esta forma, la situación problemática inicial —la saturación de correos electrónicos que reduce la productividad y expone a riesgos de seguridad— se convierte en un problema formal de inteligencia artificial: diseñar y entrenar un clasificador que, a partir de las características de un correo, determine automáticamente si este es spam o legítimo.

Este enfoque permite una solución automatizada, escalable y precisa, capaz de procesar grandes volúmenes de correos en tiempo real, aportando valor tanto en la seguridad como en la eficiencia de los usuarios.

Definición de la variable objetivo

En el contexto de la detección de spam, la variable objetivo corresponde a la categoría que el modelo de inteligencia artificial debe predecir para cada correo electrónico. Su naturaleza es categórica binaria, ya que solo puede asumir dos posibles valores mutuamente excluyentes:

- 0 → No Spam (correo legítimo): Representa los mensajes que son relevantes para el usuario, como notificaciones importantes, comunicaciones personales o laborales, y que deben permanecer en la bandeja de entrada.

- 1 → Spam (correo no deseado): Representa los mensajes que no son relevantes o que pueden poner en riesgo al usuario, como

publicidad invasiva, intentos de phishing, malware o fraudes.

La elección de esta variable objetivo está directamente relacionada con la situación problemática planteada: el exceso de correos no deseados afecta la productividad y la seguridad de los usuarios. Al predecir si un correo es spam o no, el modelo permite:

- Automatizar el filtrado de correos, evitando que el usuario tenga que revisarlos manualmente.
- Reducir el riesgo de ciberataques, al identificar correos con contenido malicioso antes de que sean abiertos.
- Optimizar el tiempo del usuario, asegurando que los mensajes importantes no se pierdan entre correos basura.

Por lo tanto, la variable objetivo resume el problema de negocio en un indicador claro y medible, lo que facilita que el sistema de IA entregue un resultado útil y alineado con la necesidad original: diferenciar automáticamente entre correos legítimos y spam.

Identificación de fuentes de datos

Para entrenar un modelo de detección de spam, se necesita un conjunto de datos que contenga una gran cantidad de correos electrónicos ya etiquetados como spam o no spam. Las fuentes de datos pueden ser:

- **Datasets públicos:** Existen varios datasets de investigación disponibles, como el Enron-Spam Dataset o el SpamAssassin Public Corpus. Estos son ideales para fines de investigación y desarrollo.
- **Datos internos de una organización:** Una empresa o proveedor de correo electrónico (como Gmail o Outlook) puede usar sus propios datos anónimos y agregados para entrenar modelos

personalizados, asegurando que el modelo se adapte a los tipos de spam que reciben sus usuarios.

Descripción del flujo de trabajo para abordar el problema

El proceso para crear un sistema de detección de spam con machine learning sigue estos pasos clave:

1. **Recopilación y Preprocesamiento de Datos:** Se obtienen los datos (emails y sus etiquetas). El texto de los correos se limpia eliminando caracteres especiales, se convierte a minúsculas y se tokeniza (se divide en palabras). Luego, se elimina el ruido, como las palabras muy comunes (ej. "el", "la", "un"), proceso conocido como eliminación de stop words.
2. **Ingeniería de Características:** El texto crudo no puede ser entendido por los algoritmos, así que se transforma en representaciones numéricas. Esto se puede hacer con técnicas como:
    - Bag-of-Words (Bolsa de Palabras): Se crea un vector que cuenta la frecuencia de cada palabra en el correo.
    - TF-IDF (Term Frequency-Inverse Document Frequency): Asigna una puntuación a cada palabra que refleja su importancia en un correo en relación con el corpus completo.
3. **División de Datos:** El conjunto de datos se divide en tres partes:
    - Conjunto de Entrenamiento: Para entrenar el modelo.
    - Conjunto de Validación: Para ajustar los hiperparámetros del modelo.
    - Conjunto de Prueba: Para evaluar el rendimiento final del modelo con datos que nunca ha visto.
4. **Entrenamiento del Modelo:** Se elige un algoritmo (como Naive Bayes o SVM) y se entrena con el conjunto de entrenamiento.

5. **Evaluación del Modelo:** Se usan métricas como la precisión, el recall y la exactitud para medir qué tan bien el modelo predice los correos spam en el conjunto de prueba.
6. **Despliegue e Integración:** Una vez que el modelo está entrenado y validado, se integra en un sistema de correo electrónico para que pueda clasificar los nuevos correos en tiempo real.

Conclusiones

El problema de los correos no deseados representa una amenaza significativa tanto para la productividad de los usuarios como para la seguridad digital, debido a la gran cantidad de mensajes fraudulentos o irrelevantes que llegan diariamente a las bandejas de entrada.

La formulación del problema como un desafío de clasificación supervisada en inteligencia artificial permite estructurar una solución clara y viable, basada en el uso de algoritmos de machine learning que aprenden a diferenciar entre correos legítimos y spam.

La definición de la variable objetivo binaria (spam/no spam) facilita la medición del desempeño del modelo, garantizando que el sistema pueda tomar decisiones automáticas y escalables en tiempo real.

La selección de fuentes de datos adecuadas, como datasets públicos (ej. SpamAssassin o Enron) o datos internos de organizaciones, es fundamental para garantizar la calidad y representatividad del entrenamiento del modelo.

El flujo de trabajo planteado, que incluye desde la recopilación de datos hasta el despliegue del modelo, demuestra que la inteligencia artificial es una herramienta efectiva para resolver problemas prácticos de la vida cotidiana y que su implementación genera beneficios tangibles en términos de eficiencia y seguridad.

Referencias

- Alpaydin, E. (2020). *Introduction to Machine Learning* (4th ed.). MIT Press.
- Guzella, T. S., & Caminhas, W. M. (2009). A review of machine learning approaches to spam filtering. *Expert Systems with Applications, 36*(7), 10206-10222. https://doi.org/10.1016/j.eswa.2009.02.037
- Metsis, V., Androutsopoulos, I., & Paliouras, G. (2006). Spam filtering with Naive Bayes – Which Naive Bayes? *CEAS 2006 - Third Conference on Email and Anti-Spam*. https://www.ceas.cc/2006/
- SpamAssassin Public Corpus. (2006). Apache Software Foundation. https://spamassassin.apache.org/publiccorpus/
- Zhang, L., Zhu, J., & Yao, T. (2004). An evaluation of statistical spam filtering techniques. *ACM Transactions on Asian Language Information Processing, 3*(4), 243–269. https://doi.org/10.1145/1037811.1037812